

GRUPO 7 SEGUROS

Residência NTT DATA & Porto Digital

Arthur Cavalcanti | Jardel Simplício
Manoel Nascimento | Paulo Nery
Rámon Taffarel | Susan Capelo



OBJETIVO GERAL

- Analisar a base de dados de dois datasets do setor de seguros para identificar gargalos operacionais e oportunidades de melhoria na experiência do cliente.
- Desenvolver insights de negócios a carteira de apólices e o fluxo de sinistros.



Susan Capelo

Liderança do projeto,
gestão do time e
estruturação do GitHub e
do storytelling.

DIVISÃO DO TRABALHO

- **Susan Capelo | Liderança & Estratégia**

Atuação como Project Lead, orquestrando as entregas técnicas, gestão do GitHub e a narrativa de negócio.

- **Manoel Nascimento | Camada Bronze & Visualização**

Responsável pela Ingestão de Dados (Bronze) e Storytelling Visual.. Realizou a entrada dos dados brutos e tradução dos insights finais em gráficos estratégicos para a tomada de decisão.

- **Paulo Nery | Camada Prata (Data Quality & Text Mining)**

Tratamento de Encoding e Normalização de Texto. Resolveu problemas críticos de codificação de caracteres (mojibake), desenvolvendo scripts de substituição para corrigir grafias corrompidas e garantir a legibilidade total dos dados textuais.



Susan Capelo

Liderança do projeto, gestão do time e estruturação do GitHub e do storytelling.

DIVISÃO DO TRABALHO

- **Jardel Simplício | Camada Prata (Saneamento)**

Qualidade de Dados e Padronização. Realizou o tratamento crítico das bases (padronizações), transformando dados sujos em informações confiáveis.

- **Arthur Cavalcanti e Ramón Taffarel | Camada Ouro (Analytics)**

Inteligência de Negócio e KPIs. Desenvolveram as agregações complexas e regras de negócio, gerando os indicadores de 'Risco por Segmento' e 'Perfil do Cliente' (Camada Ouro).



Susan Capelo

Liderança do projeto, gestão do time e estruturação do GitHub e do storytelling.

CONTEXTO DE NEGÓCIO

- **Cenário de Mercado**

Setor em expansão (>10% a.a.), pressionado por digitalização e competidores que usam dados para personalizar ofertas. Quem não segmenta, perde margem.

- **Problema**

- **Cegueira Operacional:** Gestão massificada de 60 mil vidas, sem distinção entre clientes de Varejo e Alta Renda (Q3), nem visibilidade sobre quem eram os "Heavy Users" (que acionam o seguro repetidamente).
- **Risco de Compliance:** Ausência de auditoria em contratos com conflito de interesses, como Autosseguro, expondo a empresa a fraudes.



Susan Capelo

Liderança do projeto, gestão do time e estruturação do GitHub e do storytelling.

ARQUITETURA MEDALHÃO

1 **Fontes de Dados**
Arquivos CSV
Dados Legados (Seguros & Sinistros) com formatação mista.



2 **Camada Bronze**
Ingestão Bruta
Leitura dos arquivos originais via Spark. Manutenção do dado "como veio" para auditoria.



3 **Camada Prata**
Saneamento e Qualidade

- Correção de Encoding .
- Conversão de Tipos (Texto -> Float/Date).
- Integração de dados (segurosxsinistros)



4 **Camada Ouro**
Inteligência e Agregação

- Feature Engineering (Criação de Região, Sexo).
- Segmentação (Quartis de Capital).
- Cálculo de KPIs (Sinistralidade).



5 **Visualização**
Insights de Negócio
Tabelas analíticas, Gráficos de perfil e Dashboards.



Susan Capelo
Liderança do projeto, gestão do time e estruturação do GitHub e do storytelling.

Ferramentas Utilizadas



CAMADA BRONZE

```
python
//Leitura do CSV
caminho_csv = "/Volumes/workspace/default/arquivos-nttdata/CSV -NTTDATA/seguros_vida_grande.csv"

df_seguros = spark.read \
    .format("csv") \
    .option("header", "true") \
    .option("inferSchema", "true") \
    .option("sep", ";") \
    .load(caminho_csv)
```



Manoel Nascimento

Responsável pela Ingestão
de Dados (Bronze) e
Storytelling Visual..

[Clique aqui para ver
o código completo](#)

CAMADA BRONZE

```
python

//Conversão de colunas numéricas (string → número)
colunas_para_converter = [
    "valor_pagamento", "valor_premio",
    "Valor Cob 1", "Valor Cob 2",
    "Valor Cob 3", "capital_segurado"
]

for nome_coluna in colunas_para_converter:
    df_seguros = df_seguros.withColumn(
        nome_coluna,
        regexp_replace(nome_coluna, ",", ".").cast("decimal(18,2)")
    )
```



Manoel Nascimento

Responsável pela Ingestão
de Dados (Bronze) e
Storytelling Visual..

**Clique aqui para ver
o código completo**

CAMADA BRONZE

```
python
//Verificação de nulos
from pyspark.sql.functions import col, count, when

contador_nulo = [
    count(when(col(c).isNull(), c)).alias(c)
    for c in df_seguros.columns
]

display(df_seguros.select(contador_nulo))
```



Manoel Nascimento

Responsável pela Ingestão
de Dados (Bronze) e
Storytelling Visual..

[Clique aqui para ver
o código completo](#)

CAMADA PRATA | DATA QUALITY & TEXT MINING

```
python
//Função de diagnóstico — onde detectamos caracteres corrompidos
bytes_quebrados = re.findall(b'[\x80-\xff]+', token)

if bytes_quebrados:
    palavra_formatada = ""
    for b in token:
        if b > 127:
            palavra_formatada += f"\\x{b:02X}"
        else:
            palavra_formatada += chr(b)
```



Paulo Nery

Tratamento de Encoding
e Normalização de Texto.

[Clique aqui para ver
o código completo](#)

CAMADA PRATA | DATA QUALITY & TEXT MINING

python

//Mapa de substituições — a parte chave do conserto

```
replacement_map = {  
    b'\xc7\xef': "ç".encode('utf-8'),  
    b'\xc7\x9c': "ã".encode('utf-8'),  
    b'\xc7\xe0': "í".encode('utf-8'),  
    b'\xc7\xad': "â".encode('utf-8'),  
    b'\xc7\xbd': "â".encode('utf-8'),  
    b'\xc7\xa7': "ú".encode('utf-8'),  
    b'\xc7\xb8': "é".encode('utf-8'),  
}
```



Paulo Nery

Tratamento de Encoding
e Normalização de Texto.

[Clique aqui para ver
o código completo](#)

CAMADA PRATA | DATA QUALITY & TEXT MINING

python

//Função de correção — o ponto principal

```
with open(input_path, 'rb') as f:  
    content = f.read()
```

```
for bad_bytes, good_bytes in replacement_map.items():  
    content = content.replace(bad_bytes, good_bytes)
```

```
with open(output_path, 'wb') as f:  
    f.write(content)
```



Paulo Nery

Tratamento de Encoding
e Normalização de Texto.

[Clique aqui para ver
o código completo](#)

CAMADA PRATA | SANEAMENTO

python

//Definição dos Schemas

```
seguros_schema = StructType([
    StructField("nome_contratante", StringType(), True),
    StructField("nr_documento_contratante", StringType(), True),
    StructField("cidade_contratante", StringType(), True),
    StructField("estado_contratante", StringType(), True),
    StructField("numero_apolice", IntegerType(), True),
    StructField("data_contratacao", DateType(), True),
    StructField("valor_pagamento", DoubleType(), True),
    StructField("valor_premio", DoubleType(), True),
    StructField("nome_beneficiario", StringType(), True),
    StructField("status_apolice", StringType(), True),
    StructField("Cobertura1", StringType(), True),
    StructField("Valor Cob 1", DoubleType(), True),
    StructField("Cobertura2", StringType(), True),
    StructField("Valor Cob 2", DoubleType(), True),
    StructField("Cobertura3", StringType(), True),
    StructField("Valor Cob 3", DoubleType(), True),
    StructField("capital_segurado", DoubleType(), True)
])
```



Jardel Simplicio

Qualidade de Dados e
Padronização.

**Clique aqui para ver
o código completo**

CAMADA PRATA | SANEAMENTO

python

//Normalização de Strings

```
def normalize_string(col_name):  
    c = F.upper(F.trim(col_name))  
    src = "ÁÉÍÓÚÀÈÌÒÙÂÊÎÔÛÃÕÑÇÆÏÖÜ"  
    dst = "AEIOUAEIOUAEIOUAONCAEIOU"  
    return F.translate(c, src, dst)
```



Jardel Simplicio

Qualidade de Dados e
Padronização.

[Clique aqui para ver
o código completo](#)

CAMADA PRATA | SANEAMENTO

python

//Integração Seguros + Sinistros

```
df_seg = df_seg.withColumn("key_contratante", normalize_string(F.col("nome_contratante")))
```

```
df_sin = df_sin.withColumn("key_segurado", normalize_string(F.col("nome_segurado")))
```

```
df_seg_dedup = df_seg.dropDuplicates(["nome_contratante", "nome_beneficiario"])
```

```
join_cond = [  
    df_seg_dedup["key_contratante"] == df_sin["key_segurado"]  
]
```

```
df_joined = df_seg_dedup.join(df_sin, join_cond, "left") \  
    .drop(df_sin["nome_segurado"]) \  
    .drop(df_sin["nome_beneficiario"]) \  
    .drop("key_contratante", "key_segurado")
```



Jardel Simplício

Qualidade de Dados e
Padronização.

**Clique aqui para ver
o código completo**

CAMADA PRATA | SANEAMENTO

python

//Classificação Automática por Região

```
regiao_map = {  
    "Norte": ["AC", "AP", "AM", "PA", "RO", "RR", "TO"],  
    "Nordeste": ["AL", "BA", "CE", "MA", "PB", "PE", "PI", "RN", "SE"],  
    "Centro-Oeste": ["DF", "GO", "MT", "MS"],  
    "Sudeste": ["ES", "MG", "RJ", "SP"],  
    "Sul": ["PR", "RS", "SC"]  
}  
  
region_expr = F.when(F.col("estado_contratante").isNull(), "Desconhecido")  
for region, states in regiao_map.items():  
    region_expr = region_expr.when(F.col("estado_contratante").isin(states), region)  
  
df_joined = df_joined.withColumn("REGIAO", region_expr.otherwise("Outro"))
```



Jardel Simplício

Qualidade de Dados e
Padronização.

[Clique aqui para ver
o código completo](#)

CAMADA PRATA | SANEAMENTO

python

//Enriquecimento com Base de Nomes (Sexo)

```
df_names_raw = spark.read.format("csv").option("header", "true")\
    .schema(nomes_schema).load(caminhoNomes)
```

```
df_names = df_names_raw.withColumn(\
    "first_name", F.explode(F.split(F.col("names"), "\\|"))\
).select(\
    F.col("first_name"),\
    F.col("classification").alias("SEXO")\
)
```

```
first_name_raw = F.split(F.col("nome_contratante"), " ")[0]\
df_joined = df_joined.withColumn(\
    "primeiro_nome_join",\
    normalize_string(first_name_raw)\
)
```

```
df_joined = df_joined.join(\
    df_names,\
    df_joined.primeiro_nome_join == df_names.first_name,\
    "left"\
).drop("primeiro_nome_join", "first_name")
```



Jardel Simplicio

Qualidade de Dados e
Padronização.

**Clique aqui para ver
o código completo**

CAMADA PRATA | SANEAMENTO

python

//Cálculo de Quartis e Flags de Outliers

```
q_premio = df_joined.approxQuantile("valor_premio", [0.25, 0.75], 0.01)
q_capital = df_joined.approxQuantile("capital_segurado", [0.25, 0.75], 0.01)

df_joined = df_joined.withColumn("ACIMA_DE_3_QUARTIL_PREMIO", F.col("valor_premio") > q3_premio) \
    .withColumn("ABAIXO_DE_1_QUARTIL_PREMIO", F.col("valor_premio") < q1_premio) \
    .withColumn("ACIMA_DE_3_QUARTIL_CAPITAL", F.col("capital_segurado") > q3_capital) \
    .withColumn("ABAIXO_DE_1_QUARTIL_CAPITAL", F.col("capital_segurado") < q1_capital)
```



Jardel Simplício

Qualidade de Dados e
Padronização.

[Clique aqui para ver
o código completo](#)

CAMADA PRATA | SANEAMENTO

python

//Métricas Derivadas (Acidentes + Razões)

//Contagem de acidentes

```
w_segurado = Window.partitionBy("nome_contratante")
df_joined = df_joined.withColumn(
    "QTD_ACIDENTES_POR_NOME_SEGURADO",
    F.count("tipo_sinistro").over(w_segurado)
)
```

//Razões de pagamento

```
df_joined = df_joined.withColumn(
    "RAZÃO_PAGAMENTO_PREMIO",
    F.col("valor_pagamento") / F.col("valor_premio")
).withColumn(
    "RAZÃO_PAGAMENTO_CAPITAL",
    F.col("valor_pagamento") / F.col("capital_segurado")
)
```



Jardel Simplício

Qualidade de Dados e
Padronização.

**Clique aqui para ver
o código completo**

CAMADA OURO | ANALYTICS

python

//Segmentação de perfis de clientes

```
q1, q3 = df_prep.approxQuantile("capital_segurado", [0.25, 0.75], 0.01)
```

```
df_prep = df_prep.withColumn(  
    "FAIXA_CAPITAL",  
    F.when(F.col("capital_segurado") <= q1, "BAIXO")  
    .when(F.col("capital_segurado") >= q3, "ALTO")  
    .otherwise("MEDIO")  
)
```



Rámon Taffarel

Inteligência de Negócio e
KPIs

[Clique aqui para ver
o código completo](#)

CAMADA OURO | ANALYTICS

python

//Criação do dataset mestre com métricas

```
df_freq_acidentes = df_sinistros.groupby("nome_contratante") \
    .agg(F.count("*").alias("qtd_acidentes"))

df_analise = df_prep.join(df_freq_acidentes, "nome_contratante", "left")

df_analise = df_analise.withColumn(
    "razao_pag_cap",
    F.col("valor_pagamento") / F.col("capital_segurado")
).withColumn(
    "razao_contratos_acidentes",
    F.col("qtd_contratos") / F.col("qtd_acidentes")
)
```



Rámon Taffarel

Inteligência de Negócio e
KPIs

[Clique aqui para ver
o código completo](#)

CAMADA OURO | ANALYTICS

python

//Análise de autosseguro

```
df_auto = df_analise.filter(  
    F.upper(F.col("nome_contratante")) == F.upper(F.col("nome_beneficiario"))  
)
```

//Clientes mais frequentes

```
df_mais_frequentes = df_analise.orderBy(  
    F.col("qtd_contratos").desc()  
) .limit(10)
```



Rámon Taffarel

Inteligência de Negócio e
KPIs

[Clique aqui para ver
o código completo](#)

CAMADA OURO | ANALYTICS

python

//Análise por faixa de capital

```
df_alto_capital = df_analise.filter(F.col("FAIXA_CAPITAL") == "ALTO")  
df_baixo_capital = df_analise.filter(F.col("FAIXA_CAPITAL") == "BAIXO")
```

//Eficiência da Carteira (Contratos por Acidente)

```
df_eficiencia = df_analise.select(  
    "nome_contratante",  
    "qtd_contratos",  
    "qtd_acidentes",  
    (F.col("qtd_contratos") / F.col("qtd_acidentes")).alias("eficiencia_carteira")  
)
```

```
df_eficiencia = df_eficiencia.orderBy(F.col("eficiencia_carteira").desc())
```



Rámon Taffarel

Inteligência de Negócio e
KPIs

**Clique aqui para ver
o código completo**

CAMADA OURO | ANALYTICS

python

//Cálculo de Ticket Médio e Severidade por Região

```
df_analise_valores = df_seguros.groupby("REGIAO").agg(  
    F.avg("capital_segurado").alias("Media_Capital"),  
    F.stddev("capital_segurado").alias("DesvioPadrao_Capital"),  
    F.avg(F.when(F.col("valor_sinistro") > 0, F.col("valor_sinistro"))).alias("Media_Custo_Sinistro"),  
    F.stddev(F.when(F.col("valor_sinistro") > 0, F.col("valor_sinistro"))).alias("DesvioPadrao_Sinistro")  
)
```



Arthur Cavalcanti
Inteligência de Negócio e
KPIs

[Clique aqui para ver
o código completo](#)

CAMADA OURO | ANALYTICS

python

```
//Pivot de status e cálculo percentual  
df_pivot_status = df_seguros.groupby("REGIAO") \  
    .pivot("status_apolice") \  
    .count() \  
    .na.fill(0)  
  
df_status_percentual = df_pivot_status.join(df_total_regiao, "REGIAO")  
exprs = [(F.col(c) / F.col("total_regiao") * 100).alias(f"Porcentagem {c}") for c in colunas_status]
```



Arthur Cavalcanti
Inteligência de Negócio e
KPIs

[Clique aqui para ver
o código completo](#)

CAMADA OURO | ANALYTICS

python

//Região vs. Razão Pagamento/Prêmio (Rentabilidade)

```
df_rentabilidade = df_seguros.groupby("REGIAO").agg(  
    F.avg("RAZÃO_PAGAMENTO_PREMIO").alias("Media Razao"),  
    F.percentile_approx("RAZÃO_PAGAMENTO_PREMIO", 0.5).alias("Mediana Razao"),  
    F.max("RAZÃO_PAGAMENTO_PREMIO").alias("Maximo Razao")  
)  
.orderBy("Mediana Razao")  
  
display(df_rentabilidade)
```



Arthur Cavalcanti
Inteligência de Negócio e
KPIs

[Clique aqui para ver
o código completo](#)

CAMADA OURO | ANALYTICS

python

//Criação das colunas de tempo

```
df_base = df_seguros.withColumn("teve_sinistro", F.when(F.col("regiao_sinistro") == "null", 0).otherwise(1))
```

```
df_tempo = df_base \
    .withColumn("ano", F.year("data_contratacao")) \
    .withColumn("trimestre_unico", F.concat_ws("-", F.col("ano"), F.col("TRIMESTRE")))
```



Arthur Cavalcanti

Inteligência de Negócio e
KPIs

[Clique aqui para ver
o código completo](#)

CAMADA OURO | ANALYTICS

python

//Cálculo de seguros e sinistros por trimestre

```
df_trimestral = df_tempo.groupby("ano", "TRIMESTRE", "trimestre_unico").agg(  
    F.count("*").alias("qtd_seguros"),  
    F.sum("teve_sinistro").alias("qtd_sinistros")  
)
```

//Quantidade por tipo de sinistro

```
df_tipos_sinistro = df_tempo.filter("teve_sinistro = 1") \  
    .groupBy("trimestre_unico", "tipo_sinistro") \  
    .count()
```



Arthur Cavalcanti

Inteligência de Negócio e
KPIs

**Clique aqui para ver
o código completo**

CAMADA OURO | ANALYTICS

python

//Representatividade dos sinistros no ano

```
window_ano_tipo = Window.partitionBy("ano", "tipo_sinistro")
```

```
df_razao_sinistro = df_tempo.filter("teve_sinistro = 1") \
    .groupBy("ano", "TRIMESTRE", "tipo_sinistro").count() \
    .withColumn("total_ano", F.sum("qtd_trimestre").over(window_ano_tipo)) \
    .withColumn("razao_trimestral", F.col("qtd_trimestre") / F.col("total_ano"))
```



Arthur Cavalcanti

Inteligência de Negócio e
KPIs

[Clique aqui para ver
o código completo](#)

CAMADA OURO | ANALYTICS

python

// Representatividade dos status dos seguros

```
window_ano_status = Window.partitionBy("ano", "status_seguro")
```

```
df_razao_status = df_tempo \
    .groupBy("ano", "TRIMESTRE", "status_seguro").count() \
    .withColumn("total_ano", F.sum("qtd_trimestre").over(window_ano_status)) \
    .withColumn("razao_trimestral", F.col("qtd_trimestre") / F.col("total_ano"))
```






Arthur Cavalcanti

Inteligência de Negócio e
KPIs

[Clique aqui para ver
o código completo](#)

VISUALIZAÇÃO

Regiões Dashboards




Manoel Nascimento

Responsável pela Ingestão de Dados (Bronze) e Storytelling Visual..

VISUALIZAÇÃO

Dashboard Sexo



Manoel Nascimento



Responsável pela Ingestão de Dados (Bronze) e Storytelling Visual..

VISUALIZAÇÃO



Manoel Nascimento
Responsável pela Ingestão
de Dados (Bronze) e
Storytelling Visual..

Trimestres



RETROSPECTIVA ÁGIL

- **O que deu bom**

1. Nosso pipeline no Databricks, não só rodou, como gerou insights valiosos.
2. Conseguimos padronizar campos de datas e valores que vieram "sujos" da origem.
3. O script processa 85.000 registros em segundos, algo inviável de fazer em planilhas manuais.

- **O que deu ruim**

1. Tivemos que lutar contra erros de caracteres (encoding).
2. Os arquivos CSV vieram com formatações monetárias mistas, o que exigiu um esforço extra de limpeza.
3. Muitos sinistros não tinham correspondência direta clara na base de apólices pelo nome exato, dificultando o "match" perfeito.
4. Dificuldade de usar a ferramenta de criação de gráficos do Databricks.



Susan Capelo

Liderança do projeto,
gestão do time e
estruturação do GitHub e
do storytelling.

RETROSPECTIVA ÁGIL

- O que faríamos diferente

O que fizemos

Começamos limpando tudo para depois buscar perguntas.

Cruzamos tabelas por "Nome Exato". Se estava "Ana Maria Souza" na apólice e "Ana M. Souza" no sinistro, o código não achava

Trabalhamos em esteira sequencial. (um esperava o outro terminar um passo para começar o outro).

O que faríamos

Definiríamos as Perguntas de Negócio (KPIs) no "Dia 0". Gastamos tempo limpando colunas que nem usamos.

Aplicaríamos Fuzzy Matching (correspondência por similaridade de texto). Como não tínhamos ID, essa técnica teria recuperado muito mais sinistros.

Teríamos feito Pair Programming nas etapas iniciais de limpeza. A passagem da camada Bronze para a Prata gerou gargalos que poderiam ser resolvidos se a validação dos dados fosse conjunta desde o início.



Susan Capelo

Liderança do projeto, gestão do time e estruturação do GitHub e do storytelling.



CONCLUSÃO

O projeto permitiu aplicar, de forma prática, todo o ciclo de engenharia e análise de dados: ingestão, padronização, limpeza, enriquecimento, criação das camadas Bronze/Prata/Ouro e construção de visualizações no Databricks. Mais do que os resultados, o principal ganho foi o aprendizado coletivo: trabalhar com dados reais, resolver problemas de encoding, estruturar pipelines escaláveis e produzir análises que conectam técnica e lógica analítica. A residência proporcionou evolução em colaboração, uso de ferramentas modernas e consolidação dos fundamentos de processamento de dados em ambiente distribuído.

